K-means em Bend: custo por iteração, número de iterações e paralelismo

João Vitor Sousa · Igor Targino
FB UNI · Análise de Algoritmos · 2026

Reprodutibilidade. Código e dados em github.com/iamjoaovytor/kmeans-bend: `kmeans.bend` (algoritmo), `referencia.py` e `validar.py` (referência em Python e conferência), `medir.py` e `caso_medio.py` (medições), `relatorio/figuras.py` (figuras). Todas as medições num Apple M4 Pro (8 núcleos de desempenho e 4 de eficiência) com Bend 2.0.36; no 2.0.37 a conferência passa igual e os tempos variam menos de 5%.

Resumo

O k-means divide n pontos em k grupos repetindo dois passos: cada ponto vai para o centro mais próximo e cada centro vai para a média do seu grupo. Provamos que uma iteração custa $\Theta(nkd)$ para qualquer entrada, que o algoritmo sempre termina em no máximo k^n iterações e que o melhor caso é uma única iteração; o pior caso pode exigir um número exponencial de iterações [8]. Como o caso médio não tem fórmula simples, medimos: em 400 conjuntos de dados, a média foi de 14 iterações para dados com grupos e 66 para dados uniformes. Implementamos o algoritmo em Bend, uma linguagem funcional que executa em paralelo na CPU e na GPU; os resultados coincidem com uma referência em Python, o tempo por iteração cresce linearmente em n e em k, e 12 núcleos tornam cada iteração 3,9 vezes mais rápida.

1 Introdução

Agrupar dados parecidos sem rótulos prévios é um problema comum: segmentar clientes por perfil de compra, reduzir as cores de uma imagem ou agrupar textos a partir dos vetores gerados por modelos de linguagem. O k-means, na forma de Lloyd [5] e MacQueen [6], é a solução mais usada para isso.

A entrada é um conjunto P de n pontos em $\mathbb{R}^d$ e o número k de grupos. A saída é um centro c_j por grupo e o grupo de cada ponto. O objetivo implícito é diminuir o custo

$$J = \sum_{j=1}^{k} \sum_{x \in P_j} \|x - c_j\|^2,$$

a soma das distâncias ao quadrado de cada ponto ao centro do seu grupo.

Com milhões de pontos, duas perguntas importam: quanto custa cada iteração e quantas iterações são necessárias. Uma terceira é prática: quanto do trabalho pode ser dividido entre núcleos. Este relatório responde às três, com provas e medições.

2 O algoritmo

2.1 Pseudocódigo

O algoritmo de Lloyd, com o custo de cada linha em comentário (I é o número de iterações):

```
K-MEANS(P, k)
  C ← k pontos de P            // Θ(k·d)
  repita                       // I vezes
    para cada p em P           // n vezes
      grupo[p] ← mais perto    // k × Θ(d)
    para cada grupo j          // somas Θ(n·d)
      C[j] ← média do grupo    // Θ(k·d)
  até C não mudar
  devolve C, grupo
```

2.2 Implementação em Bend

Em Bend, o paralelismo vem de uma única construção: `a b = f(x) g(y)` executa as duas chamadas ao mesmo tempo [7]. Por isso os pontos ficam numa árvore binária balanceada, e o passo 1 desce essa árvore dividindo o trabalho:

```
def assign(+pts: Pts, +cs: List<&2, C>, +b: Nat) -
> Sums:
  match pts:
    case PLeaf{+x, +y}:
      caminho(b, nearest(cs, x, y, 0, 0, 1.0e30),
x, y)
    case PNode{l, r}:
      e d = assign(l, cs, b) assign(r, cs, b)
      juntar(e, d)
```

Em cada folha, `nearest` compara o ponto com os k centros. As somas de cada grupo voltam pela árvore numa estrutura esparsa indexada pelo número do grupo: um ponto cria só o caminho até o seu grupo ($\log k$ nós), e `juntar` com um lado vazio não custa nada. O passo 2 divide cada soma pela quantidade de pontos. O laço para quando os centros se movem menos que 10^{-6} ao todo. A implementação usa $d = 2$ e números `F32`.

3 Operação básica

A operação mais repetida é a distância (ao quadrado) entre um ponto e um centro, $\sum_{i=1}^{d} (x_i - c_i)^2$: d subtrações, d multiplicações e $d - 1$ somas, ou seja, custo $\Theta(d)$. A raiz quadrada é dispensável, porque comparar distâncias ao quadrado dá a mesma ordem. Todas as demais operações (somar um ponto no seu grupo, dividir as somas) acontecem no máximo uma vez por ponto ou por grupo em cada iteração.

4 Análise

4.1 Custo de uma iteração

Teorema 1. *Para $n, k \geq 1$, uma iteração do k-means custa $\Theta(nkd)$, para qualquer entrada.*

Prova. O passo 1 calcula, para cada um dos n pontos, a distância até cada um dos k centros, ao custo $\Theta(d)$ cada: $c_1 nkd$ operações. O passo 2 soma cada ponto no seu grupo ($c_2 nd$) e divide k somas ($c_3 kd$). Logo $T = c_1 nkd + c_2 nd + c_3 kd$. Como $nd \leq nkd$ e $kd \leq nkd$, vale $c_1 nkd \leq T \leq (c_1 + c_2 + c_3)nkd$, que é a definição de $\Theta(nkd)$. Nenhum termo depende dos valores dos pontos, então não há melhor nem pior caso dentro de uma iteração. □

O custo total é, portanto, $\Theta(I \cdot nkd)$, e toda a variação entre entradas está em I.

4.2 O algoritmo sempre termina

Lema 1. *Nenhum dos dois passos aumenta J.*

Prova. No passo 1, os centros estão fixos e cada ponto passa a usar o centro mais próximo, então a sua parcela em J não aumenta. No passo 2, os grupos estão fixos. Para um grupo P_j com média μ e qualquer ponto c, vale a identidade

$$\sum_{x \in P_j} \|x - c\|^2 = \sum_{x \in P_j} \|x - \mu\|^2 + |P_j| \cdot \|\mu - c\|^2,$$

porque o termo cruzado $2\sum_x (x - \mu) \cdot (\mu - c)$ é zero. Então a média minimiza a soma, e trocar c_j por μ não aumenta J. □

Teorema 2. *O k-means termina em no máximo k^n iterações.*

Prova. Suponha que, em caso de empate, o ponto continue no grupo atual. Então, enquanto o algoritmo não para, o passo 1 move pelo menos um ponto para um centro estritamente mais próximo, e J cai estritamente; pelo Lema 1, o passo 2 não o faz subir. Depois do passo 2, os centros são as médias dos grupos, então o valor de J ao fim de cada iteração depende só do agrupamento. Como esse valor cai estritamente a cada iteração, nenhum agrupamento se repete. Existem no máximo k^n formas de atribuir n pontos a k grupos, então há no máximo k^n iterações. □

Nossa implementação desfaz empates escolhendo o centro de menor índice, e não o grupo atual; empates exatos de distância em `F32` não ocorreram nos testes. A Figura 1 mostra J medido numa execução: ele cai em todas as 61 iterações, 47% logo na primeira.

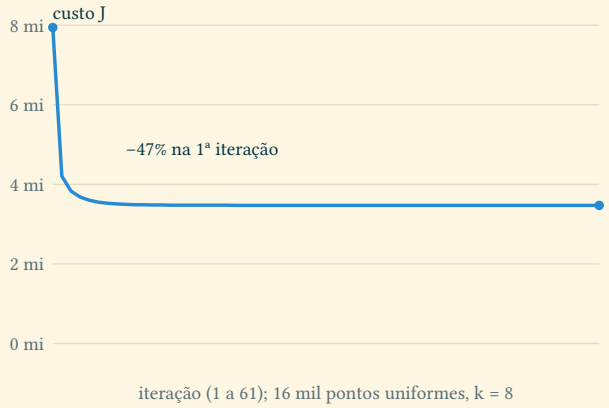


Figura 1: Custo J por iteração numa execução com 16 mil pontos uniformes e $k = 8$, medido no programa em Bend.

4.3 Melhor, pior e caso médio

Melhor caso. Se os centros iniciais já são as médias dos seus grupos, a primeira iteração não muda nada e o algoritmo para: $I = 1$ e custo $\Omega(nkd)$.

Pior caso. O Teorema 2 dá $O(k^n \cdot nkd)$. O limite não é só folga da prova: Vattani [8] construiu entradas no plano ($d = 2$) que exigem $2^{\Omega(n)}$ iterações.

Caso médio. Não há fórmula simples. Arthur, Manthey e Röglin [2] mostram que, com uma pequena perturbação aleatória nos dados, o número esperado de iterações é polinomial, o que explica por que na prática são poucas. Medimos esse comportamento na Seção 5.

4.4 Trabalho e profundidade

Com o algoritmo em paralelo, interessa também a profundidade D: o tempo com núcleos ilimitados [4]. Numa iteração, o trabalho é $W = \Theta(nkd + n \log k)$: as distâncias mais a montagem das somas esparsas. A árvore de pontos tem altura $\log n$; cada folha faz $O(kd)$ e cada junção de somas custa no máximo $O(k)$, então $D = O(kd + k \log n)$. Pelo teorema de Brent [3], com p núcleos o tempo é no máximo $W/p + D$. Para n grande, D é desprezível diante de W/p, e o ganho ideal seria próximo de p.

5 Experimentos

5.1 Validação

Uma referência em Python reproduz a mesma aritmética `F32` e a mesma ordem de somas. Em 10 configurações (variando n, k, tipo de dado e semente), o programa em Bend e a referência terminaram com o mesmo número de iterações, os mesmos centros (diferença máxima $4 \cdot 10^{-6}$) e o mesmo J a cada iteração (diferença relativa abaixo de 10^{-7}), e J nunca aumentou.

5.2 Custo por iteração

Medimos o tempo de uma iteração rodando 10 e 20 iterações e dividindo a diferença por 10, o que exclui a geração dos pontos (melhor de 3 execuções). A Figura 2 mostra que o

tempo cresce linearmente com n: a cada $4\times$ mais pontos, cerca de $4\times$ mais tempo. Com $n \approx 10^6$ e $k = 8$, são cerca de 8 ns por distância, já incluindo as somas.

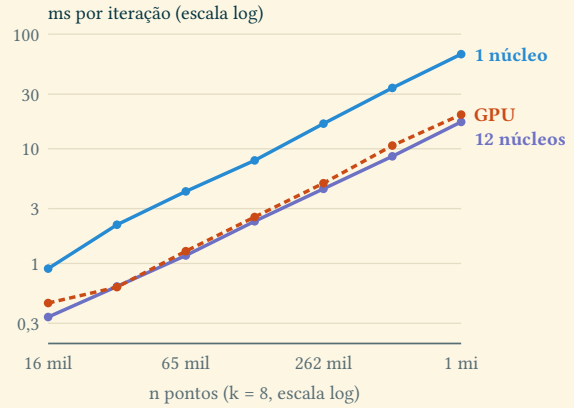


Figura 2: Tempo por iteração em função de n, com $k = 8$: 1 núcleo, 12 núcleos e GPU.

n	1 núcleo	12 núcleos	GPU
16 mil	0,90 ms	0,34 ms	0,45 ms
65 mil	4,25 ms	1,17 ms	1,28 ms
262 mil	16,5 ms	4,48 ms	5,01 ms
1 milhão	67,1 ms	17,2 ms	19,9 ms

Tabela 1: Tempo por iteração, $k = 8$.

5.3 Caso médio

Rodamos o algoritmo em 400 conjuntos de dados diferentes, com 16 mil pontos e $k = 8$: 200 com 8 grupos de verdade e 200 uniformes (Figura 3). Com grupos, a média foi de 14,4 iterações (desvio 11,1, de 2 a 91); uniformes, 66,1 (desvio 30,1, de 24 a 159). Nenhuma execução se aproximou do limite teórico: na prática o k-means é rápido, e mais rápido justamente quando os dados têm a estrutura que ele procura.

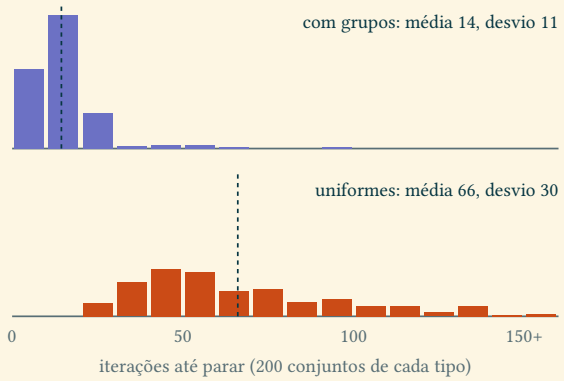


Figura 3: Iterações até parar em 400 execuções ($n = 16\,384$, $k = 8$). Linha tracejada: média.

5.4 Otimização

A primeira versão criava, em cada ponto, uma lista com as k somas, quase toda de zeros, e juntava listas inteiras em cada nó: um custo extra de $\Theta(nk)$ em alocação. A versão com somas esparsas reduz esse custo para $\Theta(n \log k)$ sem mudar a operação básica. Com $n \approx 10^6$ e $k = 8$, o tempo por iteração caiu de 190 para 67 ms em 1 núcleo, de 55 para 17 ms em 12 núcleos e de 70 para 20 ms na GPU. A Figura 4 mostra o efeito ao variar k: antes o tempo dobrava a cada k dobrado; depois segue $ank + bn \log k$, e o termo nk ainda domina quando k cresce.

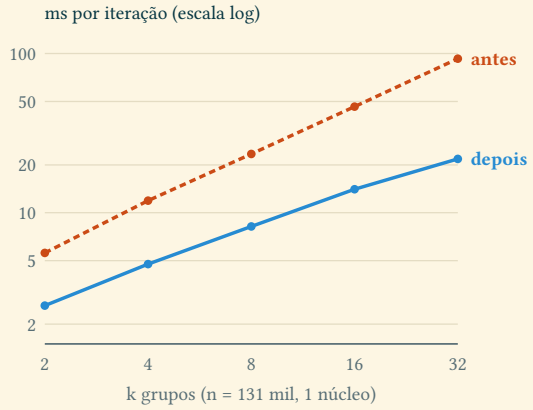


Figura 4: Tempo por iteração em função de k ($n = 131\,072$, 1 núcleo), antes e depois das somas esparsas.

5.5 Paralelismo

Com 12 núcleos, cada iteração ficou 3,9 vezes mais rápida e, na GPU, 3,4 vezes (Tabela 1). O ganho fica longe dos 12 que o teorema de Brent permitiria e para de crescer a partir de 8 núcleos. Um perfil de execução mostra o tempo concentrado na criação dos nós das somas, não nas distâncias, o que sugere que o limite é a alocação de memória; não verificamos essa hipótese além do perfil.

6 Conclusão

O custo de uma iteração do k-means é previsível, $\Theta(nkd)$, e os testes confirmaram o crescimento linear em n e em k. O número de iterações não é: vai de 1 a k^n em teoria, mas nas medições ficou em média entre 14 e 66, e o custo J caiu em todas as iterações, como o Lema 1 garante. Em Bend, uma única linha de código distribui o passo 1 entre núcleos, e somas esparsas tornaram cada iteração três vezes mais rápida.

Duas extensões ficaram de fora: testar dimensões $d > 2$ (a análise vale para qualquer d, mas só medimos $d = 2$) e comparar a inicialização aleatória com a do k-means++ [1], que escolhe centros iniciais espalhados e costuma reduzir o número de iterações.

Referências

[1] David Arthur e Sergei Vassilvitskii. 2007. k-means++: the advantages of careful seeding. Em *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, 2007. 1027–1035.

[2] David Arthur, Bodo Manthey, e Heiko Röglin. 2011. Smoothed analysis of the k-means method. *Journal of the ACM* 58, 5 (2011).

[3] Richard P. Brent. 1974. The parallel evaluation of general arithmetic expressions. *Journal of the ACM* 21, 2 (1974), 201–206.

[4] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, e Clifford Stein. 2009. *Introduction to Algorithms* (3.º ed.). MIT Press.

[5] Stuart P. Lloyd. 1982. Least squares quantization in PCM. *IEEE Transactions on Information Theory* 28, 2 (1982), 129–137.

[6] James MacQueen. 1967. Some methods for classification and analysis of multivariate observations. Em *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1967. 281–297.

[7] Victor Taelin, Lorenzo W. Battistela, Paulo J. Cavalcanti, Nicolas Abril, Vitor Chiarelli Neves, e Vanessa Ostroski. 2026. *BendRT: A Parallel Runtime for CPUs and GPUs*. Obtido de https://github.com/bendlang/bend/blob/main/paper/BendRT.pdf

[8] Andrea Vattani. 2011. k-means requires exponentially many iterations even in the plane. *Discrete & Computational Geometry* 45, 4 (2011), 596–616.